

RAPPORT CHALLENGE

Modélisation de la prime d'assurance dans le cadre d'un contrat Multirisque Agricole.

Auteur :
DELAR Emmarius

Rang 1/87

Pour le cours Génération de Données en IA par Transport et Débruitage au Collège de France

AssurPrime : Saurez-vous prédire la prime d'assurance ?

Emmarius Delar

(delaremmarius@gmail.com)

18 Mars 2024

Table des matières

1	Introduction	3
2	Étude du modèle de référence et premières optimisations	4
2.1	Dataset	4
2.2	Méthode d'évaluation	4
2.3	Modèle de référence	4
2.4	Optimisation du modèle de référence	5
3	État de l'art des méthodes	6
3.1	L'algorithme XGBoost	6
3.2	Random Fourier Features	6
4	Résultats et conclusion	7

1 Introduction

Contexte Le changement climatique entraîne naturellement une adaptation de nos sociétés aux risques qui y sont liés. Les aléas et catastrophes climatiques s'intensifient, l'un des secteurs économiques les plus exposés est celui de l'agriculture. Selon l'Observatoire des forêts françaises¹, le changement climatique serait, d'ici 2050, responsable de l'extension des zones à haut risque de feux de forêts vers le nord de la France.

Dans ce contexte, il est nécessaire pour les agriculteurs de pouvoir assurer leur activité le plus efficacement possible. C'est dans cette optique que le groupe Crédit Agricole Assurance intervient via le contrat Multirisque Agricole. Ce contrat couvre l'intégralité des risques liés à l'activité des agriculteurs², notamment les risques d'incendie, qui représentent une part importante de la charge contractuelle.

Pour déterminer la charge annuelle (ou le montant des cotisations) liée au risque incendie, il est courant d'utiliser une modélisation de la prime pure d'incendie, qui repose sur une approche fréquence - coût moyen. Cette approche consiste à estimer, d'une part, la fréquence des sinistres sur une année et, d'autre part, le coût moyen annuel engendré.

La fréquence des sinistres et leur coût moyen sont tous deux modélisés à l'aide d'un modèle linéaire généralisé, respectivement selon une loi de Poisson et une distribution de Tweedie.

Problématique L'objectif de ce challenge est donc de trouver une alternative robuste au classique GLM utilisé pour la modélisation de la fréquence et du coût moyen dans la prédiction de la prime pure d'incendie.

Plan de travail Pour répondre à cette problématique, j'ai tout d'abord reproduit puis étudié en profondeur le modèle de référence basé sur les modèles linéaires généralisés afin d'identifier les axes d'amélioration pertinents. Les résultats obtenus m'ont permis d'orienter mon état de l'art et de sélectionner des modèles susceptibles d'améliorer la prévision de la charge. Enfin, j'ai implémenté et optimisé les méthodes sélectionnées dans mon état de l'art, avant de les comparer avec le modèle de référence optimisé.

Note : Le code source est disponible sur GitHub.

1. <https://foret.ign.fr/themes/les-incendies-de-foret-et-de-vegetation>

2. <https://challengedata.ens.fr/participants/challenges/161/>

2 Étude du modèle de référence et premières optimisations

Cette section consiste à pour but d’analyser le sujet du challenge et l’approche de référence utilisé. On note l’échantillon i de la base de données comme le couple (X_i, Y_i) , avec $Y \in \mathcal{Y}, X \in \mathcal{X}$.

2.1 Dataset

Pour ce challenge, un dataset d’entraînement contenant **383 000** lignes et un dataset de test contenant **95 000** lignes sont à disposition. Tous deux contiennent **368** variables. L’importance de chaque ligne est déterminée par la variable `annee_assurance`, qui définit le taux d’exposition sur l’année d’un assuré. Pour notre problème, les variables catégorielle ont été encodé avec une approche d’encodage par comptage, qui consiste à attribue à chaque catégorie son nombre d’apparition.

2.2 Méthode d’évaluation

Les modèles étant définis, nous avaluons leurs performances à travers l’erreur quadratique moyenne (RMSE en anglais) donnée par la formule :

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (1)$$

avec y_i la i -ème charge réelle, $\hat{y}_i$ la prévision associée, où $i \in \mathbb{N}, 1 \leq i \leq n$.

Pour valider les modèles, j’ai séparé le jeu de données en un ensemble d’entraînement qui représente 80% du jeu de données et les 20% restant ont été utilisé comme ensemble de validation. Une fois le modèle validé, je réentraîne le modèle sélectionné sur l’ensemble du jeu de données avant d’effectuer de nouvelle prédiction sur l’ensemble de test et de le soumettre sur la plateforme du challenge¹ qui retourne un score pour le jeu de données test.

2.3 Modèle de référence

La modélisation se fait à partir de deux sous modèle qui une fois combiné permettent d’obtenir la charge annuelle.

Modèle linéaire généralisé (GLM) Le modèle linéaire généralisé est une approche stochastique de la regression linéaire classique, qui consiste à supposer que pour chaque échantillon (X_i, Y_i) , indépendant et identiquement distribué, on a la relation $Y_i = f(X_i, \epsilon_i)$, avec f un opérateur linéaire. Pour construire f , il faut déterminer (hypothetiquement) la distribution de la loi conditionnelle de Y sachant X sous réserve qu’elle face partie de la famille des loi exponentiel, ainsi qu’une fonction de lien g tel que $g(\mathbb{E}[Y | X]) = f(X)$.

Modèles de références Les modèles de références sont tous deux caractérisé comme suit :

Le modèle de référence est celui proposé par l’organisateur, Crédit Agricole Assurance, à savoir un GLM avec une distribution de Poisson et une fonction de lien `log` pour la modélisation de la fréquence des sinistres et un GLM avec une loi de Tweedie et une fonction de lien `Log` comme décrit par le Tableau.1. Sur la plateforme de test, le modèle proposé `benchmark` a une RMSE de 5617,6225 et se situe à la 72^{ème} place (sur 87) au 18 mars 2025 (date de rendu des travaux).

1. <https://challengedata.ens.fr/participants/challenges/161/ranking/public>

Modèle	Distribution	Fonction de lien
Fréquence des sinistres	Loi de Poisson	Log
Coût moyen d'un sinistre	Tweedie	Log

TABLE 1 – *Modélisation de la fréquence et du coût moyen des sinistres*

Partant de cette base, j'ai calibré un modèle avec des performances similaires, résumées dans le Tableau 2.

Modèle	α_{freq}	α_{cm}	power_{cm}	RMSE public	RMSE interne
Benchmark	nan	nan	nan	5617,6225	nan
Reproduction	0.15	5.25	1.95	5612,552	7042.44

TABLE 2 – *Comparaison du modèle benchmark et de la tentative de reproduction*

2.4 Optimisation du modèle de référence

Optimisation de la base d'entraînement Une part importante des performances des modèles provient de la qualité des données. C'est pourquoi j'ai choisi de modéliser la base de données. Les colonnes contenant plus de 70% de valeurs manquantes ont été supprimées, ainsi que les lignes comportant plus de 50% de valeurs manquantes, ce qui a conduit à la suppression de 1532 lignes. Certaines variables, notamment celles liées à la surface (SURFACE1, ..., SURFACE20), à la température (commençant par NBJTX) et à la pluviométrie (commençant par NBJRR), importées initialement sous forme de chaînes de caractères, ont été converties en valeurs numériques. Enfin, les données manquantes restantes ont été imputées par la moyenne de leur variable respective.

Réduction de dimension L'étape de réduction de dimension permet d'obtenir un modèle parcimonieux qui ne surajuste pas le bruit. Dans cette optique, j'ai exploré plusieurs méthodes de réduction de dimension, notamment la régression *Partial Least Squares* (PLS) et une architecture de type auto-encodeur. Cependant, en termes de compromis entre complexité et performance, l'**analyse en composantes principales** (ACP) a donné les meilleurs résultats.

Encodage ordinal L'approche consistant à encoder les variables catégorielles en utilisant un simple comptage est une solution simpliste. Après avoir testé plusieurs méthodes d'encodage, plus ou moins complexes, j'ai finalement retenu l'**encodage ordinal**, qui offre un bon compromis entre simplicité et efficacité.

Modèle	α_{freq}	α_{cm}	power_{cm}	ACP	RMSE public	RMSE interne
Benchmark	nan	nan	nan	/	5617,6225	nan
Reproduction	0.15	5.25	1.95	/	5612,552	7042.44
Optimisé	0.15	5.25	1.95	0.4	5600,74	7327.76

TABLE 3 – *Comparaison du modèle de référence optimisé, du modèle benchmark et de la tentative de reproduction*

En accord avec le résumé des scores obtenues dans le Tableau.3, cette approche a permis de perdre environ 12 points de RMSE, faisant de ce modèle le deuxième plus performant sur la plateforme de test, avec un score de 5600,74.

3 État de l'art des méthodes

Dans cette section, je présente les deux approches sélectionnées à l'issue de mon état de l'art.

3.1 L'algorithme XGBoost

Le boosting est une approche d'apprentissage qui permet de minimiser les pertes empiriques de la forme Eq. 1 en approximant la meilleure combinaison linéaire d'arbres binaires :

$$g(x) = \sum_{m=1}^M \alpha_m h_m(x)$$

qui minimise Eq. 1, où $\hat{y} = g(x_i)$ [Friedman, 2001].

L'algorithme XGBoost [Chen and Guestrin, 2016] reprend cette idée en utilisant une approximation de second ordre, c'est-à-dire :

$$g_t(x) = g_{t-1}(x) + h_t(x) \quad (2)$$

avec $h_t(x)$ un arbre de décision.

L'algorithme est un algorithme itératif qui cherche, à chaque étape t , à minimiser :

$$\min \sum_{i=1}^n \ell(y_i, g_t(x_i)) + \lambda \sum_{j=1}^b h_j^2.$$

3.2 Random Fourier Features

Une autre approche très puissante pour résoudre des problèmes de régression est la *Kernel Ridge Regression*¹. Cette approche utilise une fonction appelée *kernel*² pour calculer une matrice de similarité entre les observations de la base de données. Cette matrice remplace alors la matrice de covariance classiquement utilisée en *Ridge Regression*.

Le problème d'optimisation de la *Ridge Regression* classique est défini par :

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{n} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2. \quad (3)$$

En *Kernel Ridge Regression*, ce problème est équivalent à résoudre :

$$\hat{\alpha} = \arg \min_{\alpha \in \mathbb{R}^n} \frac{1}{n} (\mathbf{K}\alpha - \mathbf{y})^\top (\mathbf{K}\alpha - \mathbf{y}) + \lambda \alpha^\top \mathbf{K}\alpha, \quad (4)$$

avec

$$\beta = \sum_{i=1}^n \alpha_i K(x_i, x), \quad (5)$$

en utilisant le *Representer Theorem*³.

Cependant, notre problème se situe dans un cadre de grande échelle, ce qui nous empêche de calculer, stocker et manipuler la matrice de Gram de nos données, qui contient 360.000^2 éléments.

1. https://mva-kernel-methods.github.io/course-page/static_files/materials/slides.pdf

2. https://mva-kernel-methods.github.io/course-page/static_files/materials/slides.pdf

3. https://en.wikipedia.org/wiki/Representer_theorem

Pour contourner cette difficulté, nous utilisons l’approche des *Random Fourier Features*, qui permet d’**approximer la matrice de Gram** par :

$$K(x, y) \approx \phi_M(x)^\top \phi_M(y),$$

où $\phi_M(u)$ représente un vecteur de dimension M .

Cette approche offre des performances comparables à celles de la *Kernel Ridge Regression* [Rudi and Rosasco, 2017] pour $M = O(\sqrt{n} \log n)$, réduisant ainsi le nombre d’éléments à $O(nM)$ au lieu de $O(n^2)$. La complexité du problème passe donc de $O(n^3)$ à $O(M^3)$. Dans notre cas, $n \gg M$, ce qui rend le problème solvable sur un ordinateur standard.

Le code source utilisé pour ce modèle est disponible sur GitHub¹.

4 Résultats et conclusion

Cette section présente les résultats obtenus avec les différentes approches de modélisation implémentées. Pour que leur inter-comparaison soit équitable, nous avons évalué les différents modèles

Modèle	ACP	RMSE public	RMSE interne	Temps
Benchmark	/	5617,6225	nan	nan
Reproduction	/	5612,552	7042.44	12.85s
Optimisé	0.4	5600,74	7327.76	0.28s
RFF-reg	/	5604,85	7333.60	1H50
XGBoost	0.37	5599,86	7327.72	1.68s

TABLE 4 – *Comparaison des modèles*

Le modèle RFF-reg correspond ici au modèle de ridge regression basé sur l’approche des Random Fourier Features.

En accord avec le Tableau.4, c’est le modèle XGBoost qui est le plus performant et qui surpasse les GLM, qui donnent en général les meilleurs résultats.

Malgré son approche visant à réduire la complexité de l’algorithme de Kernel Ridge Regression, le modèle RFF-reg reste très coûteux à entraîner, avec environ 2 heures de calcul. En conséquence, il est compliqué d’optimiser les hyperparamètres du modèle.

Envisager une méthode efficace de paramétrisation fait partie des perspectives pour ce modèle, qui est très performant même sans une paramétrisation pointue des hyperparamètres.

Dans la même logique, pour l’algorithme XGBoost, la combinaison de l’approche de boosting avec l’approche de Kernel Ridge Regression [Aravkin et al., 2016] est une autre perspective qui pourrait donner des résultats très significatifs.

Références

- Aleksandr Y Aravkin, Giulio Bottegal, and Gianluigi Pillonetto. Boosting as a kernel-based method. *arXiv preprint arXiv :1608.02485*, 2016.
- Tianqi Chen and Carlos Guestrin. Xgboost : A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, pages 785–794, 2016.

1. <https://github.com/tiskw/random-fourier-features/tree/main>

- Jerome H Friedman. Greedy function approximation : a gradient boosting machine. *Annals of statistics*, pages 1189–1232, 2001.
- Alessandro Rudi and Lorenzo Rosasco. Generalization properties of learning with random features. *Advances in neural information processing systems*, 30, 2017.