



WWW.DAUPHINE.PSL.EU

18.03.2025

Challenge Data

InsurPrime - Pouvez-vous deviner la prime d'assurance ?

Emmarius DELAR

M2 IASD

Rang: 1/87

Introduction

- **Contexte:** Le changement climatique accroît les risques pour l'agriculture, notamment les incendies, ce qui motive l'étude de nouvelles approches de modélisation de la charge annuelle des agriculteurs.
- **Problématique :** Trouver une alternative robuste au GLM.
- **Objectif :** Explorer des approches originales de machine learning pouvant résoudre ce problème de régression.

I. Baseline

Baseline: Setup

- **Base de données:** Grande base de données avec des variables mixtes
- **GLM:** Approach stochastique de la régression linéaire

Modèle	Distribution	Fonction de lien
Fréquence des sinistres	Loi de Poisson	Log
Coût moyen d'un sinistre	Tweedie	Log

TABLE 1 – *Modélisation de la fréquence et du coût moyen des sinistres*

- **Métrique:**

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Baseline: Optimisation

Optimisation de la base d'apprentissage

- **Suppression de colonne/ ligne trop creuse**
- **Traitement du format des variables:**
 - **Surface**
 - **Température**
 - **Pluviométrie**
- **Réduction de dimension**
- **Encodage ordinal**

Baseline: Résultats

Premier résultats

Modèle	α_{freq}	α_{cm}	power_{cm}	ACP	RMSE public	RMSE interne
Benchmark	nan	nan	nan	/	5617,6225	nan
Reproduction	0.15	5.25	1.95	/	5612,552	7042.44
Optimisé	0.15	5.25	1.95	0.4	5600,74	7327.76

TABLE 3 — *Comparaison du modèle de référence optimisé, du modèle benchmark et de la tentative de reproduction*

II - XGBoost

XGBoost



- **Boosting:**

- **Minimise :**
$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **Avec $\hat{\mathbf{y}}$ =**
$$g(x) = \sum_{m=1}^M \alpha_m h_m(x)$$

XGBoost

- **Boosting:**



Ref. @Econoscent on YouTube

XGBoost

- **XGBoost:**

- **Minimise :**
$$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} + \lambda \sum_{j=1}^b h_j^2.$$

- **Avec** $\hat{\mathbf{y}} = g_t(x) = g_{t-1}(x) + h_t(x)$

III – Random Fourier Features

Random Fourier Features

- **Kernel Ridge Regression:**

- **Méthode a noyaux**

- **fonction kernel**

- **Representer Theorem**

$$\beta = \sum_{i=1}^n \alpha_i K(x_i, x)$$

- **Reformulation du problème d'optimisation**

$$\hat{\beta} = \arg \min_{\beta} \frac{1}{n} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2 \quad \hat{\alpha} = \arg \min_{\alpha \in \mathbb{R}^n} \frac{1}{n} (\mathbf{K}\alpha - \mathbf{y})^\top (\mathbf{K}\alpha - \mathbf{y}) + \lambda \alpha^\top \mathbf{K}\alpha$$

- **Problème de grande dimension**

Random Fourier Features

- **Random Fourier Features:**

- **Approximation** $K(x, y) \approx \phi_M(x)^\top \phi_M(y)$

- **Representer theorem** $\hat{f}_{\lambda, M}(x) = \phi_M(x)^\top \hat{w}_{\lambda, M}$

- **Solution** $\hat{w}_{\lambda, M} = (\tilde{S}_M^\top \tilde{S}_M + \lambda I)^{-1} \tilde{S}_M^\top \tilde{y}$

- **Complexité: $O(nM^2)$ vs $O(n^3)$**

IV – Résultats et conclusion

Résultats et conclusion

Classement: 1/87

Modèle	ACP	RMSE public	RMSE interne	Temps
Benchmark	/	5617,6225	nan	nan
Reproduction	/	5612,552	7042.44	12.85s
Optimisé	0.4	5600,74	7327.76	0.28s
RFF-reg	/	5604,85	7333.60	1H50
XGBoost	0.37	5599,86	7327.72	1.68s

TABLE 4 – *Comparaison des modèles*

Perspective

Boosting as a Kernel-Based Method

Aleksandr Y. Aravkin

*Department of Applied Mathematics
University of Washington
Seattle, WA 98195-4322, USA*

SARAVKIN@UW.EDU

Giulio Bottegal

*Department of Electrical Engineering
TU Eindhoven
Eindhoven, MB 5600, The Netherlands*

GIULIO.BOTTEGAL@GMAIL.COM

Gianluigi Pillonetto

*Department of Information Engineering
University of Padova
Padova, 35131, Italy*

GIAPI@DEI.UNIPD.IT

Editor: XXX

Abstract

Boosting combines weak (biased) learners to obtain effective learning algorithms for classification and prediction. In this paper, we show a connection between boosting and kernel-based methods, highlighting both theoretical and practical applications. In the context of ℓ_2 boosting, we start with a weak linear learner defined by a kernel K . We show that boosting with this learner is equivalent to estimation with a special *boosting kernel* that depends on K , as well as on the regression matrix, noise variance, and hyperparameters. The number of boosting iterations is modeled as a continuous hyperparameter, and fit along with other parameters using standard techniques.

We then generalize the boosting kernel to a broad new class of boosting approaches for more general weak learners, including those based on the ℓ_1 , hinge and Vapnik losses. The approach allows fast hyperparameter tuning for this general class, and has a wide range of applications, including robust regression and classification. We illustrate some of these applications with numerical examples on synthetic and real data.

Keywords: Boosting; weak learners; Kernel-based methods; Reproducing kernel Hilbert spaces; robust estimation

Merci pour votre attention!



UNIVERSITÉ PARIS DAUPHINE - PSL

Place du Maréchal de Lattre de Tassigny – 75775 Paris cedex 16